

概率论笔记

阴月有晴

国庆

手机:18576427500

邮箱 1: chenay@sustc.edu.cn

邮箱 2: achen@liv.ac.uk

目录

1	Probability	2
1.1	simple concepts	2
1.2	Computing Probability	3
2	Random Variables	3
3	Continuous Random Variables	3
4	Expected Values	6
4.1	The Expected Value of a Discrete Random Variable	6
4.2	The Expected Value of a Continuous Random Variable	6
4.3	Expectation of Function of Random Variables	7
4.4	二阶矩	7
5	Joint Distribution	8
5.1	离散型随机变量	8
5.2	连续性随机变量	9

1	PROBABILITY	2
5.3	多随机变量的函数的期望	9
5.4	期望的性质	9
5.5	方差	10
5.6	协方差	11
5.7	相关系数	11
5.8	Moment Generating Function	11
6	条件概率	12
6.1	引入概念	12

1 Probability

1.1 simple concepts

Ω 代表 sample space, ω 代表基本事件, f 代表 2^Ω , 其中有 $2^{|\Omega|}$ 个元素
 大写字母 ABC 代表事件, 大写字母 XYZ 代表随机变量
 ϕ : 例如抛四次硬币, 不可能出现反反反。

Operation of Event

- Union 并 \cup
- Intersection 交 \cap
- complement 德摩根律 $A \setminus B$
- contain $A \subset B$
- disjoint A 和 B 不可能同时发生
- 概率测度: $P: f \rightarrow [0, 1]$, 不可能事件概率为零, 概率为零的事件未必为不可能事件。必然事件亦同

概率空间: (Ω, f, p)

1.2 Computing Probability

条件概率，定义，可推广至多个。

Polya's urn schenme 一个例子

School boy 又一个例子

Law of Total Probability: Let B_1, B_2, B_i, \dots 为 Ω 的一个划分

由全概率公式可进一步推出贝叶斯公式。

独立性的含义。必然事件和零概率事件与任何事件都独立。分析定义和直观定义。并且也可以进一步推广 (由两个事件推广至 n 个事件)。

2 Random Variables

随机变量的概念: $\Omega \rightarrow \mathbb{R}$, 将事件的结果与数相关, 赋予事件以意义。在数这方面可以进行推广。

Bernouli Random variable, 一种很常见的模型。

Binomial Random variable, 是 Bernouli 由一次推广至 n 次的结果, 也可以看作是其的应用。

Poisson Random variable $\text{Poisson}(\lambda)$

Geometric Random variable 超几何分布

反过来, 可以用随机变量的结果来代表事件。

随机变量由其核心性质可分为离散型核心变量 (无穷或又穷, 可列) 和连续性随机变量。

p.m.f: 相当于根据随机变量的结果在概率空间上的划分。

c.d.f(cumulative dtribution function): 一个非降函数, 离散型随机变量会有跳跃点, 右连续和左极限。大概是反映了一种顺序吧, 类似一种格的结构。

一些离散型随机变量的分布, 如泊松分布, 伯努利分布等。

3 Continuous Random Variables

连续性随机变量: 不可列的无穷变量。

类似 p.m.f 可以在连续性随机变量定义 **p.d.f**(概率密度)。(更好的想法是从 c.d.f 上定义出来, 即要求 $F(x)$ 可微, 若不可微则为第三类随机变量),

而 c.d.f 则可以直接套用在连续性随机变量上, 名称依然为 c.d.f 没有改变

p.d.f 在某些点可以取不同的值。这只能从 c.d.f 这方面来理解。

$p(a < x \leq b) = F(b) - F(a)$, 该公式对于所有类型的随机变量均有效。且应该注意左开右闭, 对于连续性随机变量则无影响。且 $a > b$ 时右边为零而非反过来

The Exponential Distribution

The Gamma Distribution : 可以看作 Exponential Distribution 的一种更进一步的推广。

Normal Random Variables: $X \sim N(0, 1)$, $f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$, 其 c.d.f 又记为

$$\Phi(x) = \int_{-\infty}^x f(x) dx$$

由于 $f(x)$ 关于 y 轴的对称性, $\Phi(x)$ 有性质:

$$\Phi(x) = 1 - \Phi(-x)$$

其中, 可以引出 3σ 原则

General Normal Random Variables:

$$X \sim N(\mu, \sigma^2)$$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

令

$$Y = aX + b$$

则

$$Y \sim N(a\mu + b, a^2\sigma^2)$$

令

$$Y = \frac{X - \mu}{\sigma}$$

then

$$Y \sim N(0, 1)$$

function of a random variable: $R \rightarrow R$, 例如:

$$z = x^k, \text{ then } Z(\omega) = X^k \text{ is a r.v.}$$

question if $X \sim N(0, 1)$, then what is the distribution of X^2 ?

Solution : Let $Y = X^2$ and assume the c.d.f of Y is $F_Y(y)$. **answer :**

$$f_Y(y) = \begin{cases} \frac{e^{-\frac{y}{2}}}{\sqrt{2\pi y}}, & y > 0 \\ 0, & y \leq 0 \end{cases}$$

a useful general result: Suppose that $g(x)$ is a strictly monotone differentiable function of x . Then the random variable Y denoted by $Y = g(x)$ has a p.d.f. given by

$$f_Y(y) = \begin{cases} f_X[g^{-1}(y)] \cdot \left[\frac{d}{dy} g^{-1}(y) \right], & \text{if } y = g(x) \\ 0, & \text{if there is no } y = g(x) \end{cases}$$

the cauchy distribution: μ is a real number, if its p.d.f. $f_Y(y)$ is given by:

$$f_Y(y) = \frac{1}{\pi} \cdot \frac{1}{[1 + (y - \mu)^2]}, \quad (-\infty < y < \infty)$$

when $\mu = 0$ is the standard cauchy distribution.

4 Expected Values

4.1 The Expected Value of a Discrete Random Variable

Definition of expected $E(X)$, 表示随机变量的对于概率的加权平均。

$$E(X) = \sum_i p_i \cdot X_i$$

其中若上式为无穷级数, 则要求其绝对收敛, 否则无意义 (黎曼重排定理)

Binomial Distribution if $X \sim B(n, p)$, then

$$E(X) = np$$

Poisson Distribution if $X \sim \text{Poisson}(\lambda)$, then

$$E(X) = \lambda$$

The Geometric Distribution $E(X) = \frac{1}{p}$, p 代表一次成功的概率。

notes $E(X)$ does not exist

$$p.m.f p_n = \frac{1}{n(n+1)}$$

4.2 The Expected Value of a Continuous Random Variable

Definition of expected 类比离散型随机变量,

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

Standard Normal Distribution 由对称性和绝对收敛可知, Standard Normal Distribution 的 $E(X) = 0$

Gamma Distribution 利用 Γ 函数的性质可以演算出:

$$E(X) = \frac{\alpha}{\lambda}$$

The Cauchy Distribution The cauchy distribution is

$$f(x) = \frac{1}{\pi} \cdot \frac{1}{1+x^2}$$

but

$$\int_{-\infty}^{\infty} |x| f(x) dx$$

does not converge, so its $E(X)$ does not exist.

Remark

4.3 Expectation of Function of Random Variables

Problem Suppose X is a r.v., the $Y = g(X)$, how to find the $E(Y)$?

Notes

- 为什么 $E(Y) \neq g(E(X))$
- 其中的意义如何理解?
- n 阶矩的意义?

Examples Random Variable $X: -1, 0, 1$ with pmf: $P(X=-1)=0.2$, $P(X=0)=0.5$, $P(X=1)=0.3$ then

$$E(X^2) = 0.5$$

4.4 二阶矩

Notes

- $E(X^2) - (E(X))^2$ 是方差 (如何证明?)
- 矩是研究随机变量的一种工具, 类似于物理上的矩。

Question

- 如何理解 $E(X^2)$ 的意义？为什么被赋予二阶矩的意义？
- 是否有更快的计算方法？
- 对于连续性变量的方差如何定义？
- 如何理解 $E(X - Y) = E(X) - E(Y)$ 的意义？

5 Joint Distribution

5.1 离散型随机变量

Joint p.m.f 假设 X 和 Y 是定义在同一个样本空间上的离散型随机变量，则

$$p(x_i, y_j) = P(X = x_i, Y = y_j)$$

(其中涉及交运算)，称为 X 和 Y 的 the joint probability mass function，简称为 Joint p.m.f

Marginal p.m.f $p_X(\cdot)$ 称为 X 和 Y 的 the joint probability mass function 的 X 的边缘分布

M p.m.f 和 Joint p.m.f 的关系 显然 Joint p.m.f 可以决定 M p.m.f, 但是如何决定？而已知 M p.m.f, 在什么情况下可以决定 Joint p.m.f?

第一问利用全概率公式即可，类似一种降维的思想

而第二问则需要引入**独立性随机变量**的概念。因为需要知道 X 和 Y 的关系。

独立性随机变量 若对于所有的 x_i 和 y_j 有：

$$P(x_i, y_j) = P(x_i) \cdot P(y_j)$$

，联想独立事件，可以看作一个独立事件族。

Joint Cumulative Probability Distribution Function 简写为: joint c.d.f, 记作 $F_{(X,Y)}(x,y)$, 有二维递增性和概率连续性:

$$\lim_{x \rightarrow -\infty} F(x,y) = 0, \forall y \in R$$

Marginal Cumulative Probability Distribution Function

两者 c.d.f 的关系 类似 c.d.f, 但是计算方法有所改变。

5.2 连续性随机变量

类似单变量随机变量, 先建立 Joint c.d.f, 它有二维递增性和积分为 1, 以及区间性。再由偏导可以进一步定义 Joint p.d.f (Joint Probability Density Function) 以及 M p.d.f

Remark: 独立性和相关系数的关系, 相关系数为 0 未必独立, 而独立相关系数一定为 0.

5.3 多随机变量的函数的期望

多随机变量的函数, 例如 $Z = X + Y$, 是一个复合函数, 也是一个 r.v., 仍然以事件为因变量。以正向的思维来看, 这个是简单的

5.4 期望的性质

1. $E(C) = C$, C 为一常数, 你的初始理解有错误
2. $E(aX) = a \cdot E(X)$, a 为常数, X 为随机变量
3. $E(X \cdot Y) \neq E(X) \cdot E(Y)$, 并不显然
4. $E(X + Y) = E(X) + E(Y)$, 要假设其存在 p.d.f, 然后由积分可证
5. $E(aX + bY) = a \cdot E(X) + b \cdot E(Y)$, 是 2 和 4 的推论, 代表了期望的线性性质。

6. $E(\sum_{n=1}^{\infty} Y_n) = \sum_{n=1}^{\infty} E(Y_n)$, 其中要保证无穷项符号要一致
控制收敛定理: 若 $\sum_{n=1}^{\infty} E(|Y_n|)$ 有限, 则前式也成立
7. 若 X 和 Y 两者独立 (上面的定理不需要这个条件), 那么 $E(XY) = E(X) \cdot E(Y)$, 证明过程中只需要利用 $f(x, y) = f_X(x) \cdot f_Y(y)$ 套积分公式即可
进一步推广,

$$E(g(X) \cdot h(Y)) = E(g(X)) \cdot E(h(Y))$$

Remark 数学归纳法, 只对有限数有用, 不能过渡到无穷。(超限归纳法)

5.5 方差

因为 $E(X)$ 无法反映随机变量的所有性质, 无法反映其 “spread”
 $E|X - E(X)|$ 可以用来测定 “spread”, 但不好计算
为了在数学上更好的处理, 故用 $E((X - E(X))^2)$ 来定义方差

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

这个公式的证明体现了这个体系的优越性. 均方差为方差的开方。

方差的性质

1. 方差大于零
2. $\text{Var}(C) = 0$, C 为常数
3. $\text{Var}(a \cdot X) = a^2 \cdot \text{Var}(X)$, 不是线性性质, 但利用了期望的线性性质
4. 如果 X 和 Y 互相独立, 有:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

反映了方差的线性性质, 这里利用了期望的第三条性质, 虽然形式上跟第二条性质相似

5. a, b 为常数, 则

$$\text{Var}(a + bX) = b^2 \cdot \text{Var}(X)$$

5.6 协方差

Covariance:

$$\text{Cov}(X, Y) = E((X - E(X))(Y - (E(Y))))$$

它的性质蛮多的。不过均是可以由条件期望的三条性质推导出来的。它可以取任意实数，代表一种相关性

可以引出一个 Varaince Formula, 蛮有用的

5.7 相关系数

由于 Covariance 可能太大，故引进 Correlation Coefficient: $\rho(X, Y)$
其中两个方差严格大于零.

可以构造证明

$$-1 \leq \rho \leq 1$$

如果 $\rho = 1$, 则两者呈现正线性关系。

不过对于这个线性关系怎样理解？

另外，可以与线性代数来使 n 个随机变量的 Covariance 形式更漂亮

5.8 Moment Generating Function

矩发生函数, MGF

$$M_X(t) = E(e^{tX})$$

是关于 t 的实函数。

显然，

$$M_X(t) = E(e^{tX}) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

由于绝对收敛性，所以可能对某些 t 不成立

矩发生函数的性质：

1. $M_X(0) = 1$

2. If $Y = aX + b, M_Y(t) = e^{bt} M_X(at)$, 利用期望的线性性质即可。

3. If $Z=X+Y$, and X, Y are independent then $M_Z(t) = M_X(t) \cdot M_Y(t)$,
可拓展至 n 个独立随机变量

4. mgf 与其随机变量一一对应。拉氏变换的唯一性

Remark 你对几何分布的认识有问题。

矩发生函数的应用：

1. 用来求随机变量的矩：

$$M'_X(t) = \frac{d}{dt} E(e^{tX}) = E\left(\frac{d}{dt} e^{tX}\right) = E(e^{tX} X)$$

则：

$$E(X^n) = M_X^{(n)}(0)$$

称为原点矩，另外还有均值矩 $E[(X - E(X))^n]$ ，也是可以求出来的

2. 用来决定分布利用性质三和性质四可以求组合独立随机变量的分布

Remark $Y \sim \Gamma\left(\frac{1}{2}, \frac{n}{2}\right)$, 其中 $Y \sim \chi^2(n)$

6 条件概率

6.1 引入概念

首先从离散型随机变量引入。并且与 Joint p.m.f 和 Marginal p.m.f

Conditional p.m.f 是 x 的函数， y 在其中起参数的作用，

$$p_{X|Y}(x|y)$$

Conditional c.d.f 由 Conditional p.m.f 求和而得，仍然是 x 的函数

$$F_{X|Y}(x|y)$$

条件期望

$$E(X|Y=y) = \sum_x x \cdot p_{X|Y}(x|y)$$

其中要求 $p_{Yy} > 0$ ，这也是难以向连续性随机变量拓展的困难之处。

an example 如果 X 和 Y 是独立的泊松分布, 求

$$E(X|X+Y=n)$$

answer is $n \frac{\lambda_1}{\lambda_2 + \lambda_1}$

连续性随机变量的条件期望的引入 取极限就是

$$f_{X|Y}(x|y) = \frac{f(x,y)}{f_Y(y)} \quad f_Y(y) > 0$$

$$E(X|Y=y) = \int_{-\infty}^{\infty} x \cdot f_{X|Y}(x|y) /, dx$$

是 y 的函数